Модель PD покупателя: результаты обучения (версия 1.0)

27.10.2026 · Руслан · Смарт-факторинг

Итог. Модель обучена на когорте 2022 и проверена на когорте 2023, которая в настройке не участвовала. Gini на проверке 0,76 (доверительный интервал 0,75–0,77) при требовании не ниже 0,5 и цели 0,6; на сегменте выручки от 800 млн ₽ 0,84. Уровни риска A–D по доле дефолтов растут монотонно, стабильность по PSI с большим запасом. Одно замечание по калибровке: на 2023 году фактическая доля дефолтов в средних децилях выше прогноза в 1,3–1,6 раза, а в верхнем ниже на 19% (подробности в разделе 3). Утечки по датам не найдено, но не проверяемо одно: дата подачи отчётности в витрине не хранится (раздел 5).

1. Приёмка по ТЗ (когорта 2023, метка Б, окно 12 месяцев)

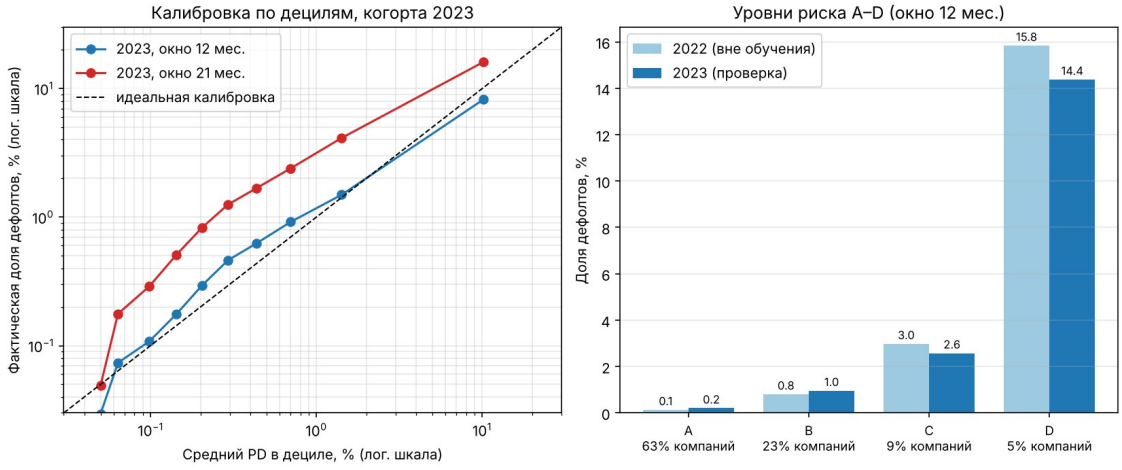
Критерий	Требование	Результат	Вывод
Gini	не ниже 0,5, цель 0,6, с доверительным интервалом	0,761 (0,747–0,774)	выполнено
Gini, выручка от 800 млн ₽	то же, отдельно	0,836 (0,814–0,856); 39 924 компаний, 536 дефолтов	выполнено
Gini, окно 21 месяц	те же метрики отдельно	0,725 (0,715–0,734); сегмент от 800 млн ₽ 0,808	выполнено
Калибровка по децилям	средний PD близок к фактической доле дефолтов	средний PD 1,36% против факта 1,24%; наибольший разрыв по децилям 1,9 п.п. (верхний дециль)	выполнено с оговоркой, раздел 3
PSI	меньше 0,25	скор 0,006; наибольший у признака 0,014	выполнено
Монотонность A–D	доля дефолтов растёт от A к D	0,2% / 1,0% / 2,6% / 14,4%	выполнено
Утечка	данных после даты среза нет; Gini выше 0,9 — повод перепроверить	Gini 0,76, максимум по одному признаку 0,52; даты подачи отчётности не проверяемы	выполнено с оговоркой, раздел 5

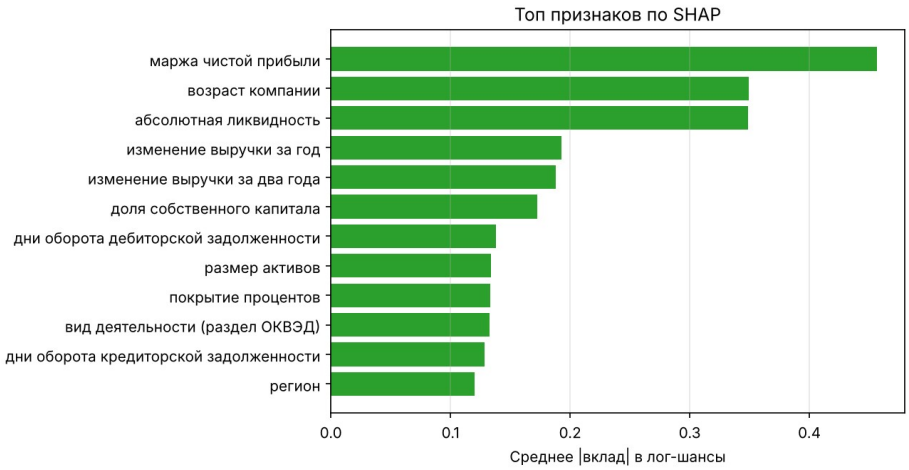
2. Что обучали

Выборка: когорта 2022 (отчётность за 2022 год, срез 01.04.2023), 174 351 строк с определённой меткой, из них 2 182 дефолтов (1,25%). Проверка: когорта 2023, 203 674 строк, 2 523 дефолтов (1,24%). Гейт 0 пройден: витрина воспроизводит списки ИНН один в один (182 584 и 210 511, расхождений нет). Фильтры из ТЗ: отчётность сдана, не выброс, без ОКВЭД K и O, выручка от 120 млн ₽.

Признаки: 28 штук по разделу 6 ТЗ (13 коэффициентов, динамика за один и два года, флаги риска, масштаб, раздел ОКВЭД и регион), поля витрины с датами и событиями после среза в выборку не попали. Модель: LightGBM с весом дефолтного класса 5 и параметрами, выбранными кросс-валидацией по 2022 (5 частей, 14 вариантов). Калибровка Platt по предсказаниям вне обучающих частей; изотоническая дала почти такой же логлосс, но ступенчатый PD. Уровни A–D заданы по 2022: A < 0,4%, B 0,4–1,5%, C 1,5–6%, D ≥ 6%.

3. Результаты на проверке 2023





Доли дефолтов по уровням риска:

Уровень	Доля компаний	2022, вне обучения	2023, 12 мес.	2023, 21 мес.
A	63%	0,13%	0,20%	0,56%
B	23%	0,81%	0,96%	2,58%
C	9%	2,98%	2,58%	6,66%
D	5%	15,84%	14,38%	25,98%

Калибровка. Ранжирование на 2023 году стабильно, но уровень PD сдвигается: в децилях 5–8 фактическая доля дефолтов выше прогноза в 1,3–1,6 раза, в верхнем дециле прогноз 10,2% против факта 8,2%. Общий средний PD 1,36% против 1,24%. На окне 21 месяц фактическая доля естественно выше (в среднем 2,7%), модель калибрована на 12 месяцев. Калибровку и границы уровней на 2023 не подгоняли, потому что это нарушило бы правило проверки.

Дециль	Средний PD	Факт	Дефолтов
1	0,05%	0,03%	6
2	0,06%	0,07%	15
3	0,10%	0,11%	22
4	0,14%	0,18%	36
5	0,20%	0,29%	60
6	0,29%	0,46%	94
7	0,43%	0,62%	127
8	0,70%	0,92%	187
9	1,42%	1,49%	304
10	10,15%	8,21%	1 672

4. Сравнение моделей и вариантов метки

Кросс-валидация по 2022 (Gini вне обучающих частей) и проверка 2023:

Модель	Кросс-валидация 2022	Проверка 2023, 12 мес.	Проверка 2023, 21 мес.
Бустинг LightGBM (выбран)	0,814	0,761	0,725
CatBoost	0,807	0,742	0,717
Логистическая регрессия со сплайнами	0,789	0,744	0,709
Логистическая регрессия линейная	0,713	0,670	0,651

Бустинг лучше линейной регрессии на 0,10 в кросс-валидации (во всех пяти частях) и на 0,09 на проверке. Регрессия со сплайнами ближе: бустинг лучше неё в среднем на 0,024 в кросс-валидации (во всех пяти частях) и на 0,016 на проверке, доверительные интервалы пересекаются. Бустинг оставлен: он впереди во всех пяти частях и на проверке, а SHAP даёт главные факторы по каждой компании. Разница со сплайновой регрессией при этом небольшая.

Варианты метки (одна модель, одни признаки и части, кросс-валидация внутри 2022):

Обучено на	Оценка на «любой дефолт» (банкротство и исключение)	Оценка на «только банкротство»
Вариант Б: банкротство и исключение	0,813	0,746
Вариант А: только банкротство	0,682	0,777
Вариант 0: любая ликвидация	0,679	0,430

Вариант Б лучше всех на «любом дефолте» и теряет около 0,03 на чистых банкротствах по сравнению с моделью, обученной только на банкротствах. Вариант 0 хуже по обеим целям: в нём реорганизации и добровольные ликвидации идут как дефолт. Выбор варианта Б по ТЗ подтверждается.

5. Проверка на утечку

Что проверено: поля витрины с событиями после среза убраны на этапе выборки (13 колонок); возраст считается как год отчётности минус год регистрации; лаги T−1 и T−2 у когорты 2023 совпадают со значениями когорты 2022 у всех 151 144 общих компаний по проверенным статьям (выручка, активы, капитал, прибыль, дебиторская задолженность); Gini ниже порога 0,9; без самого сильного признака (маржа) Gini 0,80, без маржи и абсолютной ликвидности 0,78, без возраста и признака «нет отчётности за прошлый год» 0,80; по кварталам окна Gini 0,80 / 0,83 / 0,69 / 0,71 (убывает по мере удаления от среза).

По типу дефолта: на банкротствах Gini 0,70 на проверке и 0,73 вне обучения; на исключениях из ЕГРЮЛ 0,79 и 0,86. Исключения предсказываются легче: сильнее всего работает маржа около нуля при крупной выручке, типичная для компаний-транзитёров.

Что проверить нельзя. Витрина не хранит дату подачи отчётности, поэтому не доказано, что отчётность года T была подана до 01.04 следующего года. Собственное поле витрины `pit_status` помечено как непроверенное. Если часть отчётов подана позже среза, качество на проверке могло быть завышено. Закрыть вопрос можно только датами подачи из первичного источника.

6. Боевой скоринг и решения

Для скоринга реальных покупателей подготовлена отчётность за 2024 год: 233 667 компаний по тем же фильтрам, из них 45 685 с выручкой от 800 млн ₽. Распределение на ней стабильно: PSI скора к обучению 0,001, доли уровней A/B/C/D 62% / 24% / 10% / 5%. Функция `score(inn)` возвращает PD, уровень A–D и три фактора с направлением; для компании вне выборки (нет отчётности, выручка меньше 120 млн ₽, ОКВЭД K и O) возвращает статус `no_financials`, а не низкий риск. Когда будут выбраны ~1 200 покупателей, `score_many(список ИНН)` вернёт PD, уровень и три фактора по всем сразу.

Два решения за тобой:

1. Для скоринга покупателей берём отчётность за 2024 год (подготовлена) или другой год? Модель учили на отчётности за 2022 год; год 2024 для неё допустим, но на нём нет проверки по меткам.
2. Переобучать ли модель на когортах 2022 и 2023 вместе перед боевым использованием? Так калибровка учтёт 2023 год и разрыв в децилях сократится, но независимой проверки после этого не будет, и метрики останутся из этого отчёта.

7. Что в поставке

Файл	Что это
pd_model.pkl	модель: признаки, бустинг, калибровка, границы уровней
score_inn.py	функция score(inn) и score_many(список ИНН)
scoring_store_2024.parquet	данные для скоринга: отчётность за 2024 год
pd_company_year_features_2022.parquet, _2023.parquet, pd_fields.md	таблица «компания-год» с признаками и метками, описание полей
pd_model_training_executed.ipynb	ноутбук обучения с результатами
laptop_scripts/, 0*_*.py, pd_*.py	скрипты сборки выборки и обучения (версия RFSD ca3665997c97…)
out/	таблицы и результаты: подбор параметров, сравнения, калибровка, проверки